Universidad Nacional de San Agustin

Ciencia de la Computación

Informe de la multiplicación de matrices usando *tile* modificado

Alumnas :
Judith Escalante Calcina
Profesor:
Mg.Alvaro Henry Mamani Aliaga

Índice

1. Multiplicación en cpu

La multiplicación de matrices es un proceso altamente utilizado y conocido , este funciona perfectamente con matrices pequeñas pero no con matrices de grandes dimensiones, en el siguiente código podemos ver la función principal de una multiplicación de matrices en general :

```
void cpu_matrix_mult(int *h_a, int *h_b, int *h_result,
int m, int n, int k) {
    for (int i = 0; i < m; ++i)
    {
        for (int j = 0; j < k; ++j)
        {
            int tmp = 0.0;
            for (int h = 0; h < n; ++h)
            {
                tmp += h_a[i * n + h] * h_b[h * k + j];
            }
            h_result[i * k + j] = tmp;
        }
    }
}
```

2. Multiplicación en gpu

2.1. Multiplicación sin memoria compartida

La multiplicación realiza en la gpu de una computadora es mucho más eficiente que que la hecha en la cpu , por que utiliza varios thread para cada elemento de la matriz , que qa su vez es dividida en una cierta cantidad de bloques. Aún asi este no es uno de las ejecuciones más eficientes. Aqui podemos ver el código principal:

```
__global__ void matrix_mult(int *a,int *b, int *c, int m,
int n, int k)
{
    int row = blockIdx.y * blockDim.y + threadIdx.y;
    int col = blockIdx.x * blockDim.x + threadIdx.x;
    int sum = 0;
    if( col < k && row < m)
```

```
    {
        for(int i = 0; i < n; i++)
        {
            sum += a[row * n + i] * b[i * k + col];
        }
        c[row * k + col] = sum;
    }
}
```

2.2. Multiplicación con memoria compartida (tile)

La multiplicación utilizando memoria compartida y *tileds* es una versión optimizada del producto de dos matrices, A x B, en la que cada bloque de hilos computa una submatriz o *tiled* de la matrix resultado C. Esto permite reducir el cuello de botella del ancho de banda de la memoria, puesto que varios elementos del bloque acceden a la misma fila de A y columna de B.

A su vez, esta localidad de acceso será aprovechada para utilizar la memoria compartida, lo que también nos obligará a realizar algunas sincronizaciones entre hilos dentro de un bloque. La memoria compartida dentro de cada multiprocesador se utilizará para almacenar cada submatriz antes de los cálculos, acelerando el acceso a memoria global. A continuación podemos ver el codigo principal:

```
__global__ void matrix_mult_tiled(float*A, float*B, float*C,
int ARows, int ACols, int BRows, int BCols, int CRows,
int CCols)
{

  float CValue = 0;
  int Row = blockIdx.y*TILE_DIM + threadIdx.y;
  int Col = blockIdx.x*TILE_DIM + threadIdx.x;

  __shared__ float As[TILE_DIM][TILE_DIM];
  __shared__ float Bs[TILE_DIM][TILE_DIM];

  for (int k = 0; k < (TILE_DIM + ACols - 1)/TILE_DIM; k++)
    {

      if (k*TILE_DIM + threadIdx.x < ACols && Row < ARows)
        As[threadIdx.y][threadIdx.x] =
```

```
            A[Row*ACols + k*TILE_DIM + threadIdx.x];
        else
            As[threadIdx.y][threadIdx.x] = 0.0;

        if (k*TILE_DIM + threadIdx.y < BRows && Col < BCols)
            Bs[threadIdx.y][threadIdx.x] =
            B[(k*TILE_DIM + threadIdx.y)*BCols + Col];
        else
            Bs[threadIdx.y][threadIdx.x] = 0.0;

        __syncthreads();

       for (int n = 0; n < TILE_DIM; ++n)
          CValue += As[threadIdx.y][n] * Bs[n][threadIdx.x];

        __syncthreads();

   }

   if (Row < CRows && Col < CCols)
         C[((blockIdx.y * blockDim.y + threadIdx.y)*CCols)+

   (blockIdx.x*blockDim.x)+threadIdx.x]=CValue;

}
```

Figura 1: Multiplicación usando memroia compartida

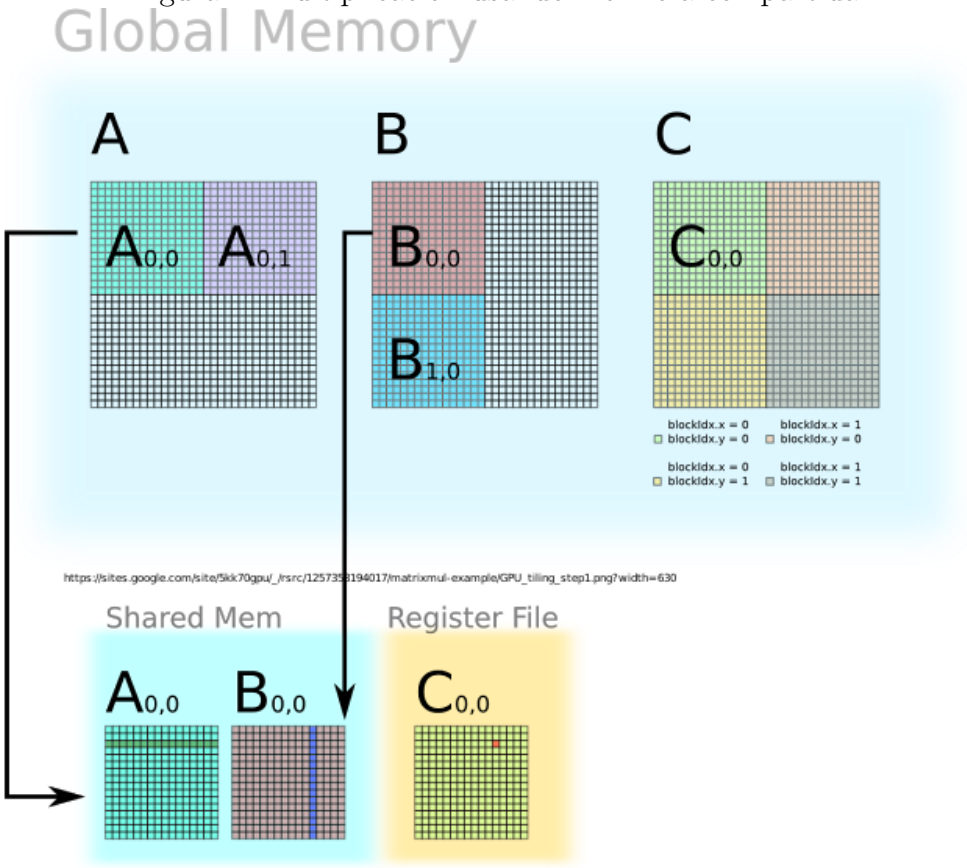

Para que la multiplicación con memoria compartida se debe tener la arquitectura del device :

Figura 2: Arquitectura del GPU

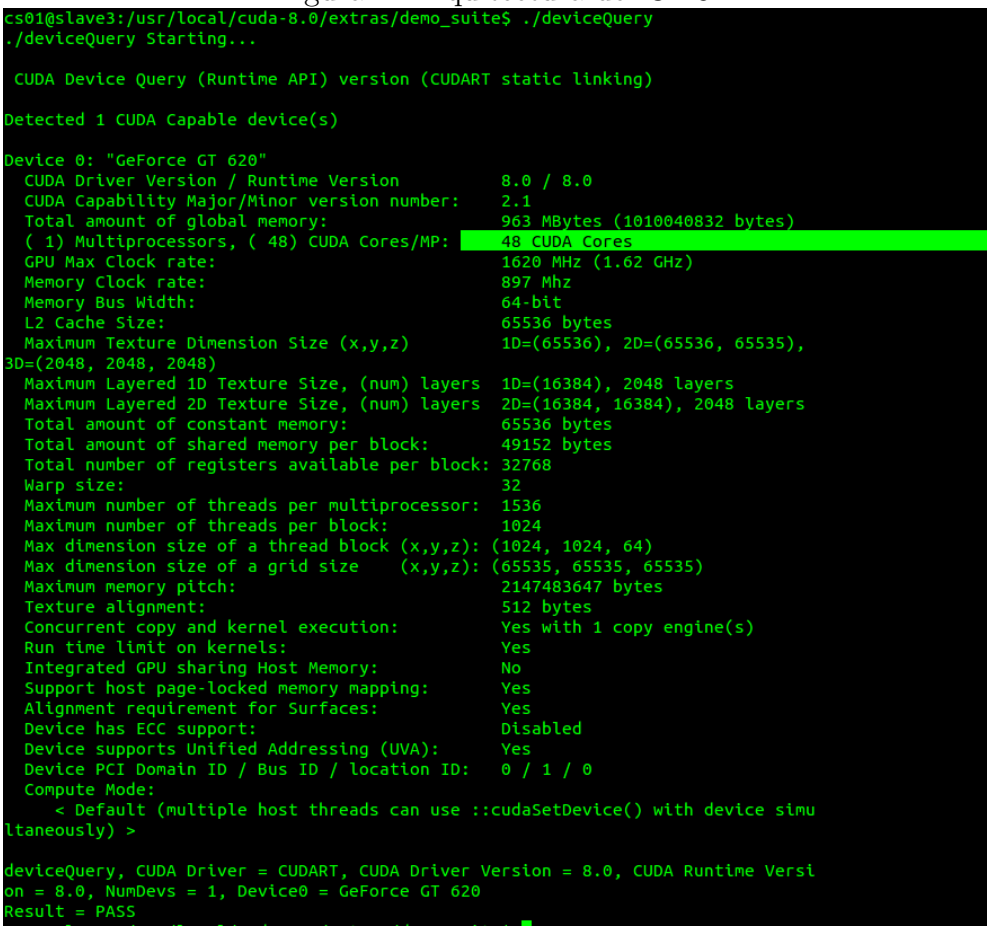

Es necesario saber el tamaño de la memoria compartida,para no exceder en el tamaño de los tiles; en este caso se esta usadondo un device GeForce GT 620 para hacer las pruebas, el cual tiene 1024 threads por bloque y 49152 de memoria compartida.

En este caso el tamaño del tile puede ser de 16 y 32 ya que no sobrepasa el tamaño de threads por bloque, ni tampoco el tamaño de la memoria compartida y también porque el tamaño de un warp es de 32 threads.Donde cada MP tiene 8 SPs (Streaming Processor = CUDA Core)

2.3. Multiplicación con memoria compartida (tile) modificada

```
__global__ void matrix_mult_tiled(float*A, float*B, float*C,
```

```
int ARows, int ACols,int BRows, int BCols, int CRows,
int CCols)

{

 float CValue = 0 , CValue2=0;
 int Row = blockIdx.y*TILE_DIM + threadIdx.y;
 int Col = blockIdx.x*TILE_DIM + threadIdx.x;

  __shared__ float As[TILE_DIM][TILE_DIM];
  __shared__ float Bs[TILE_DIM][TILE_DIM];
  __shared__ float Bs_sub[TILE_DIM][TILE_DIM];

  for (int k = 0; k < (TILE_DIM + ACols - 1)/TILE_DIM; k++)
  {
     if (k*TILE_DIM + threadIdx.x < ACols && Row < ARows)
        As[threadIdx.y][threadIdx.x] =
        A[Row*ACols + k*TILE_DIM + threadIdx.x];

      else As[threadIdx.y][threadIdx.x] = 0.0;

      if (k*TILE_DIM + threadIdx.y < BRows && Col < BCols)
      {
        Bs[threadIdx.y][threadIdx.x] =
        B[(k*TILE_DIM + threadIdx.y)*BCols + Col];

        Bs_sub[threadIdx.y][threadIdx.x] =
        B[(k*TILE_DIM + threadIdx.y)*BCols +(Col+TILE_DIM)];

      }
      else
      {
        Bs[threadIdx.y][threadIdx.x] = 0.0;
        Bs_sub[threadIdx.y][threadIdx.x] =0.0;
      }


      __syncthreads();

      for (int n = 0; n < TILE_DIM; ++n)
```

```
        {
          CValue +=As[threadIdx.y][n]*Bs[n][threadIdx.x];
          CValue2+=As[threadIdx.y][n]*Bs_sub[n][threadIdx.x]
        }


        __syncthreads();

    }

    if (Row < CRows && Col < CCols)
    C[((blockIdx.y * blockDim.y + threadIdx.y)*CCols)+
    (blockIdx.x*blockDim.x)+threadIdx.x]= CValue;

    C[(((blockIdx.y * blockDim.y + threadIdx.y)*CCols)+
    (blockIdx.x*blockDim.x)+threadIdx.x)+ TILE_DIM]= CValue2;

}
```

3. Resultados

Cuadro 1: Tabla comparativa entre los tiempos de ejecución de la multiplicación de matrices.

Tamaño de la matriz	**Matriz sin tile**	**Matriz con tile**	**Matriz modificada**
1000 x 1000	10.57	5.61	3.79
2000 x 2000	127.32	97,73	55.95
4000 x 4000	954.35	564.81	123.78
8000 x 8000	2988.04	975.96	765.54
16000 x 16000	45378.71	7492.734	7309.797

4. Conclusión

Como podemos ver en todos los casos el algoritmo ejecutado en GPU es mucho más rápido que en CPU pero aún así la misma GPU tiene algunas mejorás , como por ejemplo utilizar memoria compartida.

Para ello, se debe saber como explotar los recursos disponibles en la GPU, en el que miles de hilos pueden colaborar con un objetivo común, las optmizaciones sobre el flujo de instrucciones y el paralelismo a nivel de instrucción.

Por último podemos mejorar aun más nuestro algoritmo si generamos dos resultados a la vez como podemos ver en el algoritmo de matriz modificada , en esta podemos ver , que en vez de cargar dos veces la misma fila de la primera matriz , cargaremos dos matrices tiled de la segunda matriz , asi haremos la multiplicación con dos datos de la segunda matriz a la vez , y generaremos dos resultados que ubicaremos de forma correcta donde corresponda en la matriz resultante.